

Turizm Alanına Özgü Anlamsal Olarak İşaretlenmiş Bir Derlem

An All-Words Sense Annotated Corpus for Tourism Domain

Deniz Baran Aslan
Starlang Yazılım Danışmanlık
İstanbul, Turkey
deniz@starlangyazilim.com

Bilge Nas Arıcan
Starlang Yazılım Danışmanlık
İstanbul, Turkey
bilge@starlangyazilim.com

Tuğrul Ahmet Bayrak
EtsTur
İstanbul, Turkey

Eyüp Erkan Özbek
EtsTur
İstanbul, Turkey

Olca Taner Yıldız
Işık University
İstanbul, Turkey
olcaytaner@isikun.edu.tr

Özetçe —Türkçe doğal dil işleme, gelişmekte olan bir alandır. Türkçe zengin bir dil olarak birçok fazla anlamlı kelimeye sahiptir. Bu anlam fazlalığı özellikle, belirli bir alana özgü işaretleme çalışmalarında karışıklığa yol açabilmektedir. Bu sebeple, turizm alanına özgü yaptığımız çalışmada büyük Türkçe veri setini kullanmanın yanı sıra elle işaretleme ile en doğru derlemi hazırlamayı amaçladık. Uyguladığımız yaklaşım ile kelimelerin otomatik işaretlenmesinin doğruluğunun artmasını hedefledik ve turizm alanına özgü ilk anlamsal veri setini ortaya koyduk.

Anahtar Kelimeler—Anlamsal belirsizlik giderme, alana özgü işaretleme, kelime ağı

Abstract—Turkish natural language processing is a developing field. Due to the richness of the language, many words have multiple senses. Excessive word meanings may cause confusion especially in domain-specific annotation studies. Therefore, in our study limited to the tourism domain, we aimed to prepare a highly accurate data set with manual tagging, using a large amount of Turkish data. With the approach we applied, we aimed to increase the accuracy of the automatic tagging of words, and we present the first semantic data set specific to the tourism domain.

Keywords—Sense disambiguation, domain dependent annotation, wordnet

I. GİRİŞ

Doğal dil işleme (DDİ), dilbilim ve yapay zekayı bir araya getiren bir çalışma alanıdır. DDİ, bir dildeki metinlerin, seslerin, verilerin bilgisayar tarafından çözülmesidir. DDİ için veriye dayalı denetimli makine öğrenme algoritmaları kullanılır. Gerekli çözümlemelerin gerçekleştirilebilmesi için büyük çapta veriye ihtiyaç vardır. Veri ne kadar çok olursa, çözülme o kadar başarılı olur.

DDİ için kelimelerin anlamları oldukça önemlidir. Metin ve konuşmalar doğal dil ile üretilir, DDİ ile analiz edilir. Kelimelerin anlamını tanımlamak amacıyla kelime anlamsal belirsizliği giderme (Word Sense Disambiguation) kullanılır. WSD sayesinde kelimelerin anlamı çözümlenebilir, cümle

içerisindeki kullanımları anlamlandırılabilir. Ancak, bu teknik ile yapılan çalışmaların oranı oldukça düşüktür. WSD çalışması için sözdizimsel ilişkiler, pos etiketleri, cümlelerin biçimbilimsel özellikleri gibi pek çok ek çalışma gereklidir. Bu çalışma kaynaklarının azlığı ise WSD çalışmasını olumsuz etkiler. Sözü geçen çalışmaların hayata geçirilme oranı ne kadar artarsa, WSD'nin çalışma alanı da o kadar genişler.

Buradan yola çıkarak turizm alanına özgü anlamsal olarak işaretlenmiş bir derlem ortaya çıkardık. Çalışmanın öncesinde, Türkçe bir derlem bulunmaktaydı ancak alana özgü yapılan çalışmalarla ilgili bir veri bulunmamaktaydı. Kullandığımız veriler, turizm alanına özgüdür ve bu sebeple daha sınırlı bir küme oluşturmaktadır. Çalışmada, insan işaretleyiciler tarafından anlamları seçilen, turizm alanına özgü kelimeler üzerine odaklanılmıştır. Ortaya çıkan derlem, Türkçe derleminden daha az kelime içermekte ve daha belirli bir alana hitap etmektedir. Makalenin geri kalanı şu şekilde sıralanmıştır: İkinci bölümde çalışma alanına ait literatür özeti verilmiş, üçüncü bölümde kullanılan yöntemden bahsedilmiş, dördüncü bölümde istatistiklerle ilgili bilgi verilmiş ve beşinci bölümde sonuç üzerine yoğunlaşmıştır.

II. LİTERATÜR ÖZETİ

Halihazırda çoğu İngilizce olmak üzere birçok anlamsal işaretlemeli derlem bulunmaktadır. Bunlar arasında öne çıkanlar şunlardır: SemCor (Miller et al., 1993) [1] 190 binden fazla ögesiyle en büyük İngilizce anlamsal işaretli derlemdir, Brown derlemi üzerine inşa edilmiştir. Yine başka bir çalışma da üç farklı kaynaktan gelen veri üzerine inşa edilmiş; İngilizce line, hard ve serve kelimelerinin dört biner örneğinin anlamsal işaretlemesini bulunduran line-hard-serve derlemidir (Leacock et al., 1993) [2]. DSO derlemi (Lee ve Ng, 1996) [3], 191 İngilizce kelimenin toplamda 192.800 örneğini içeren, Brown derlemi tabanlı bir anlamsal işaretlemeli derlemdir. 288 ismin 90 bin örneğini barındıran Open Mind Word Expert (Chklovski ve Mihalcea, 2002) [4], Penn-Treebank kaynaklı başka bir

derlem çalışmasıdır.

Başka dillerde yapılan çalışmalar arasında da SemCor ile bağlantılı olarak inşa edilmiş MultiSemCor (Bentivogli et al., 2005) [5] ve SemCor-En/Ro (Lupu et al., 2005) [6] bulunmaktadır. MultiSemCor, İngilizceden aktararak anlamsal işaretlemesi yapılmış yaklaşık 93 bin İtalyanca kelime içermektedir. SemCor-En/Ro da benzer bir derlem olup Rumence dilinde 48 bin anlamsal işaretli kelimedenden oluşmaktadır.

Türkçeye gelindiğinde yine birtakım anlamsal işaretleme çalışmaları görülmektedir. ODTÜ-Sabancı Türkçe Treebank (Ofazer et al., 2003) [7], ODTÜ Türkçe derleminden elde edilen veri üzerine inşa edilmiş, 6930 cümleden oluşan kapsamlı bir anlamsal işaretlemeli derlemidir. Başka bir örnek de TDK tanımları kullanılarak işaretlemesi yapılmış, her kelimenin en az 100 örneğini barındıran Turkish Lexical Sample Dataset'tir (TLSD) (İlgen et al., 2012) [8]. Türkçe için Çoklu-Kelime Belirsizlik Giderme (Açıkgöz et al., 2017) [9] çalışması kapsamında Penn-Treebank derleminde Türkçeden çevrilmiş cümleler arasından 1400 tanesi seçilmiş, içerdikleri 13.194 kelimenin anlamı elle işaretlenmiştir. TDK tanımları kullanılarak işaretlenmiş 7,595 özgün kelimenin 83,500 örneğinden oluşan bir başka Türkçe derlem de (Akçakaya ve Yıldız, 2018) [10] tarafından oluşturulmuştur. Yine kapsamlı bir çalışma da (Arıcan et al., 2019) [11] tarafından gerçekleştirilen Penn-Treebank üzerine İngilizce ile yan yana yaklaşık 60 bin kelimenin anlamsal işaretlemesini barındırmaktadır. İşaretlemelede seçilen anlamlar için Türkçe kelime ağı KeNet (Ehsani et al., 2018) [12] kullanılmıştır. Oluşturulan derlemde çoklu kelimelere de yer verilmiş, yaklaşık dört bin çoklu kelime işaretlemesi yapılmıştır.

III. YÖNTEM

Çalışma, turizm alanına özgü verilerden oluşturulan 20.000 cümlelik derlem üzerinde gerçekleştirilmiştir. Kelimeler ve seçilecek anlamları, (Arıcan et al., 2020) [13] tarafından oluşturulan turizm kelime ağından alınmıştır. Bu kelime ağı müşterilerin internet üzerinden yaptığı yorumlar arasından 14.000 girdi seçilerek hazırlanmıştır. Anlamsal işaretleme işleminde kullanılacak iki ara yüz oluşturulmuş, süreç iki aşamaya bölünmüştür. Cümleler, bütün kelimeleri biçimbilimsel çözümleyiciden geçirilip Türkçe kelime ağındaki karşılıkları ile eşleştirilmiş halde işaretleyicinin önüne getirilmiştir. Birinci aşamada dört işaretleyici ortak olarak çalışmış, derlemdeki cümleleri tek tek gösteren ara yüz kullanılmıştır. Şekil 1'de görüldüğü üzere cümlelerin her kelimesi ayrı şekilde işaretlenebilmektedir, yukarıda bulunan düğmeler aracılığıyla cümleler değiştirilebilir. Her kelimeye basıldığında bütün mümkün anlamlar işaretleyicinin seçebilmesi için sıralanır. Bu uygulamada işaretleyiciler her sözcük için en uygun anlamı seçerek elle işaretleme yapmıştır. Nokta ve virgül gibi öğeler otomatik olarak işaretlenmiştir. Aynı zamanda işaretleyiciler "kelimenin her örneğini aynı anlamla işaretleme" işlevini kullanmış, süreç yarı otomatik hale getirilerek verimlilik artırılmıştır. Uygulamanın bu işlevi, seçilen kelimenin derlemdeki bütün örneklerini tek bir anlamla işaretler. Genelde ya da sadece turizm alanında tek bir anlama sahip kelimeler bu sayede kolayca işaretlenmiştir. Biçimbilimsel çözümleyiciden hatalı gelen cümleler, aynı araçtan elle düzeltilmiştir. Her kelime öncelikli olarak turizm sözlüğünde bulunan anlamlarla işaretlenmeye çalışılmış, turizm sözlüğünün yetersiz kaldığı yerlerde

genel Türkçe kelime ağındaki anlamlarla işaretlenmiştir.

İlk aşamada sonucunda işaretlenmeyen kelimeler olmuştur. Bu eksikleri tamamlamak ve sonuçları elle kontrol etmek amacıyla ikinci aşamaya geçilmiştir. İkinci aşamada bütün cümleler ve kelimelerin tek pencerede aynı anda görülebildiği ara yüz kullanılmıştır. Bu ara yüzde kelimeler alfabetik olarak sıraya dizilmiş, her birinin yanında da içinde geçtiği cümle belirtilmiştir. Bu sayede kelimeler birbirleri ile karşılaştırılmış, bütün derlem bağlamında anlamlarına karar verilerek işaretleme yapılmıştır. Anlamı işaretlenmeyen kelimeler, işaretlenmiş kelimelere bakılarak tamamlanmıştır. Bu aşamada iki işaretleyici çalışmış, farklı işaretleyiciler tarafından işlenen veriler arasında uyum sağlanması da gözetilmiştir.

İşaretleme sürecinde isteğe bağlı olarak otomatik işaretleme işlevi de kullanılmıştır. Bu işlev, sözlükte tek anlamı bulunan kelimeleri işaretleyiciye sormadan o anlamla eşler. Ardından bu eşleşmeler işaretleyiciler tarafından kontrol edilmiş, hatalar düzeltilmiştir. Anlamsal işaretleme uygulamasının tekli kelimeler dışında çoklu kelime öbeklerini algılama işlevi de bulunmaktadır. Bu işlev sayesinde anlamsal bir bütün oluşturan öbekler de birleşik biçimde işaretlenmiştir. Türkçede özellikle iki kelimelik fiil yapıları çok kullanılmaktadır (kabul etmek, memnun kalmak, vb.) ve bu durum turizm derlemine de yansımıştır. Kelimelerin tek başlarına kullanıldığında ortaya çıkmayan anlamları, gerekli diğer kelimelerin hemen ardında veya öncesinde bulundukları durumlarda anlamlar listesinde belirilmiş, işaretleyici tarafından seçilerek işaretlenmiştir.

İşaretleme sürecinde biçimbilimsel çözümleme hatalarının yanı sıra yazım hataları da sorunlara yol açan etmenler arasındadır. Birleşik ve ayrık olması gereken öğelerin düzeltilmesi de biçimbilimsel çözümlemenin düzeltilmesi gibi zaman kaybına sebep olmaktadır.

IV. İSTATİSTİKLER

Id	Sözcük Öbeği	Geçme Sıklığı
TUR10-1081860	.	19.995
TOU01-1010440	çok	3.016
TUR10-0388960	iyi	2.529
TUR10-0105580	bir	1.981
TOU01-1063690	memnun kalmak	1.929
TUR10-0000000	(özel isim)	1.759
TUR10-0624490	personel	1.557
TUR10-0318110	güzel	1.396
TUR10-0513570	yemek	1.330
TUR10-0495010	tesis	1.247
TUR10-0816400	ve	1.221
TUR10-0346660	hizmet	1.042
TUR10-0593590	otel	1.014
TUR10-1121820	puan vermek	1.010
TUR10-0318100	güzel	957
TUR10-0097260	bey	924
TUR10-0582130	oda	915
TUR10-0187890	değil	769
TUR10-0473520	konum	740
TUR10-0565860	ilgili	708

TABLO I: En çok işaretlenen 20 sözcük öbeği ve geçme sıklıkları

Yirmi bin cümlelerin işlenmesi sonucunda tam 93.653 kelime anlamsal olarak işaretlenmiştir. İşaretlemede ele alınan toplam anlam sayısı 1.849'dur. Bu anlamlardan sadece 111'i turizm kelime ağından gelirken geriye kalan 1.737 anlam



Şekil 1: İlk aşamada kullanılan ara yüz

File Name	Index	Word	Sense Id	SynSet	Sense De...	Sentence
8521.train	8	KATILMAK	TUR10-1242600	girmek	Katılmak	GENEL OLARAK MEMNUN KAL...
8680.train	5	KATILMAK	TUR10-1242600	girmek	Katılmak	MEMNUN KALDIM ANKET ÇALI...
9773.test	8	KATILMAK	TUR10-1242600	girmek	Katılmak	GENEL OLARAK HER ŞEYDEN...
9856.train	2	KATILMAK	TUR10-1242600	girmek	Katılmak	ANKETE KATILMAK İSTEMİYOR...
9857.train	3	KATILMAK	TUR10-1242600	girmek	Katılmak	BU ANKETE KATILMAK İSTEMİY...
4587.train	4	KATILMAYACAĞIM	TUR10-1242600	girmek	Katılmak	MÜSAİT DEĞİLİM ANKETE KATI...
5000.test	2	KATILMAYACAĞIM	TUR10-1242600	girmek	Katılmak	ANKETE KATILMAYACAĞIM .
5226.train	2	KATILMIŞTİM	TUR10-1242600	girmek	Katılmak	ANKETE KATILMIŞTİM .
8814.train	4	KATILMIŞTİM	TUR10-1242600	girmek	Katılmak	MAİL ÜZERİNDEN ANKETE KA...
9868.train	3	KATILMIŞTİM	TUR10-1242600	girmek	Katılmak	ANKET ÇALIŞMASINA KATILMIŞ...
9928.train	4	KATILMIŞTİM	TUR10-1242600	girmek	Katılmak	ANKETE DAHA ÖNCE KATILMI...
7985.train	11	KATIYOR	-	-	-	TESİSE 3. GİDİŞİM VE HER YIL ...
7986.train	17	KATIYOR	-	-	-	ÖN BÜRO TAKİMİNE ÇOK TEŞ...
7988.train	11	KATIYOR	-	-	-	TESİSE 3. GİDİŞİM VE HER YIL ...
7317.train	11	KATLA	-	-	-	ODAYI TEMİZLEYEN GÖREVLİY...
1005.test	13	KATLARA	TUR10-0810130	üst kat	Bulunula...	ERTESİ GÜN ODANIN TEMİZLE...
9325.train	5	KATTAKİ	TUR10-0427040	kat daire	Bir yapını...	AKŞAM YEMEĞİ İÇİN 4. KATTAK...

Şekil 2: İkinci aşamada kullanılan ara yüz

Türkçe kelime ağındandır. Kelime bazında bakılacak olursa işaretlenen tüm kelimelerin 8.455'i turizm kelime ağından anlam alırken geriye kalan 85.186 kelimenin anlamı Türkçe kelime ağından seçilmiştir. Oluşturulan derlemdeki dağılımları turizm kelime ağındaki dağılımla karşılaştırmak gerekirse: turizm kelime ağında bulunan 13.555 girdiden 4.788'i turizm alanına özgüken geriye kalan 8.767 girdi Türkçe kelime ağından gelmektedir.

Tablo 1'de görüldüğü üzere "değil, bir, ve" gibi dilbilgisel işlev gören kelimeler yüksek sıklıkta geçmektedir, elbette bu durum verinin hangi alandan geldiğine bakmaksızın beklenen bir sonuçtur. Bunun yanı sıra verinin turizm alanına özgü olması sebebiyle "personel, tesis, hizmet, otel" benzeri kelimelerin derlemin önemli bir kısmını oluşturduğu gözlenmektedir. Müşteri yorumlarından oluşan veride "güzel, iyi, vb." sıklıkla kullanılan sıfatlar da bolca görülmektedir. Noktalama işaretlerinin de veriye katılmasıyla doğal olarak her cümlelerin sonunda yer alan nokta, en sık geçen "kelime" olmuştur. Tablodaki sıralamaya giremeyen önemli elemanlar arasında yine dilbilgisel sözcükler, "kötü, yeterli" gibi sıfatlar ve tabii ki

virgül de bulunmaktadır. Yine öngörülen bir durum da yüksek miktarda özel isim kullanımıdır.

Yukarıda bahsedildiği üzere işaretlemelerde sözcük öbekleri de dikkate alınmıştır. Tablo 2'de görülmektedir ki öbeklerin büyük çoğunluğu "memnun kalmak, puan vermek" tarzında müşteri yorumlarında sıklıkla kullanılan ifadelerden oluşmaktadır. Ayrıca sözcük öbekleri iki kelimeyle sınırlı olmayıp, üç ve hatta dört kelimelik öbekler de işaretlenmiştir.

Tablo 3'te de görüldüğü üzere derlemdeki cümlelerin çoğunun uzunluğu üç ve altı kelime arasındadır. On kelimedenden uzun cümleler de bulunmakla beraber, fazla uzun cümleler azınlıktadır.

İki aşamalı süreç sonucunda neredeyse yüz bin kelime anlamsal olarak işaretlenmiş, işaretlemelerin önemli bir kısmının sıklıkla tekrarlanan küçük bir grup ifadeden oluştuğu gözlemlenmiştir. Bu sıklıkla tekrarlanan ifadelerin çoğu yarı otomatik şekilde işaretlenmiştir, dolayısıyla işaretleme sürecinde en fazla zaman alan kelimeler aslında bütün derlemde bir veya iki kere çıkanlar olmuştur.

Id	Sözcük Öbeği	Geçme Sıklığı
TOU01-1063690	memnun kalmak	926
TUR10-1121820	puan vermek	404
TUR10-1154960	tavsiye etmek	321
TUR10-1181550	tercih etmek	187
TUR10-0728240	güler yüzü	154
TUR10-0893550	yardımcı olmak	113
TUR10-1160460	teşekkür etmek	102
TUR10-0181700	damak tadı	51
TUR10-0847620	yeme içme	47
TOU01-1063820	aile oteli	45
TUR10-0839560	sağ olsun	43
TUR10-0227360	haberdar olmak	42
TUR10-1199410	bilgi vermek	34
TOU01-1041440	aqua park	30
TUR10-0089100	hoşuna gitmek	26
TOU01-1063770	çocuk dostu	24
TUR10-0004240	açık büfe	20
TUR10-0019600	dört dörtlük	19
TUR10-0565860	ilgi alaka	17
TUR10-0084000	her zaman	16

TABLO II: En çok işaretlenen 20 ikili sözcük öbeği ve geçme sıklıkları

Cümle Uzunluğu	Geçme Sıklığı
2	824
3	4.475
4	6.761
5	4.584
6	1.632
7	601
8	341
9	157
10	134

TABLO III: Cümle uzunlukları ve geçme sıklıkları

V. SONUÇ

Çalışma sonucunda ortaya çıkan derlemde, Türkçe kelimelerin anlamlarının çok değişken olabileceği görülmüş, bu anlamların kullanım alanlarına göre değerlendirilmesi gerektiği sonucuna varılmıştır. Bir kelimenin en çok kullanılan anlamı dahi belirli bir alan üzerinde çalışırken yanlış sonuçlar vermektedir. Değerlendirmelerin çalışma alanına göre yapılması, daha isabetli sonuçlar elde edilmesini sağlayacaktır. Gelecekteki çalışmalarımızda, alana özgü kelime ağırmızı genişletmeyi hedeflemekteyiz. Ayrıca otomatik işaretlemenin daha doğru yapılabilmesi adına, alana özgü işlemeyi kolaylaştırmayı planlamaktayız.

Doğal Dil İşleme çalışmaları en fazla İngilizce üzerinde gerçekleştirilirken Türkçe üzerinde az örnek bulunmaktadır. Özellikle alana özgü çalışmaların oranı çok düşüktür. Oluşturulan veri kümesi ile belirli bir alana ait kelimeler üzerinde

yapılan çalışma sayesinde Türkçe Doğal Dil İşleme için önemli bir kaynak ortaya konmuştur. Bu çalışma, hem Türkçe anlam-sal işaretleme hem de alana özgü anlam işaretleme açısından önem taşımaktadır. Halihazırda bulunan Türkçe veri setindeki kelime anlamları dikkate alınarak oluşturulacak alana özgü derlemeler ile Türkçe Doğal Dil İşleme çalışmalarına büyük katkı sağlanacağını ummaktayız.

KAYNAKÇA

- [1] G. A. Miller, C. Leacock, R. Teng, and R. T. Bunker, "A semantic concordance," in *ARPA Workshop on Human Language Technology*, 1993, p. 303–308.
- [2] C. Leacock, G. Towell, and E. Voorhees, "The annotation process in the Turkish treebank," in *ARPA Workshop on Human Language Technology*, 1993, p. 260–265.
- [3] H. T. Ng and H. B. Lee, "Integrating multiple knowledge sources to disambiguate word senses: An exemplar-based approach," in *34th Annual Meeting of the Association for Computational Linguistics*, 1996, p. 40–47.
- [4] T. Chklovski and R. Mihalcea, "Building a sense tagged corpus with open mind word expert," in *ACL 2002 Workshop on WSD: Recent Successes and Future Directions*, 2002, p. 116–122.
- [5] L. Bentivogli, E. Pianta, and M. Ranieri, "Multisemcor: an English Italian aligned corpus with a shared inventory of senses," in *Meaning Workshop*, 2005, p. 90.
- [6] M. Lupu, D. Trandabat, and M. Husarciu, "A Romanian semcor aligned to the English and Italian multisemcor," in *1st ROMANCE FrameNet Workshop at EUROLAN 2005 Summer School*, 2005, p. 20– 27.
- [7] K. Oflazer, B. Say, and N. B. Atalay, "The annotation process in the Turkish treebank," in *EACL Workshop on Linguistically Interpreted Corpora*, 2003.
- [8] B. Ilgen, E. Adalı, and A. C. Tantug, "Building up lexical sample dataset for Turkish word sense disambiguation," *2012 International Symposium on Innovations in Intelligent Systems and Applications*, pp. 1–5, 2012.
- [9] O. Açıkgöz, A. T. Gürkan, B. Ertopçu, O. Topsakal, B. Özenç, A. B. Kanburoğlu, İ. Çam, B. Avar, G. Ercan, and O. T. Yıldız, "All-words word sense disambiguation for Turkish," *2017 International Conference on Computer Science and Engineering (UBMK)*, pp. 490–495, 2017.
- [10] S. Akçakaya and O. T. Yıldız, "An all-words sense annotated Turkish corpus," *2018 2nd International Conference on Natural Language and Speech Processing (ICNLSP)*, pp. 1–6, 2018.
- [11] B. N. Arıcan, Ö. Bakay, B. Avar, O. T. Yıldız, and Ö. Ergelen, "English-Turkish parallel semantic annotation of penn-treebank," in *Wordnet Conference*, 2019, p. 298.
- [12] R. Ehsani, E. Solak, and O. T. Yıldız, "Constructing a wordnet for Turkish using manual and automatic annotation," *ACM Trans. Asian and Low-Resource Lang. Inf. Process.*, vol. 17, pp. 24:1–24:15, 2018.
- [13] B. N. Arıcan, S. Parlar, T. A. Bayrak, E. E. Özbek, and O. T. Yıldız, "Creating domain dependent Turkish wordnet and sentinet," in *Manuscript submitted for publication*, 2020.