

# Aynı Otelı Temsil Eden Farklı Kayıtlar İçin Akıllı Eşleştirme

## Intelligent Mapping for Hotel Records Representing the Same Entity

Ahmet Tuğrul Bayrak  
Veri Bilimi ve Analitiği Bölümü  
ETSTUR  
İstanbul, Türkiye  
tugrul.bayrak@etstur.com

Eyüp Erkan Özbek  
Veri Bilimi ve Analitiği Bölümü  
ETSTUR  
İstanbul, Türkiye  
eyup.ozbek@etstur.com

Sedat Kestepe  
Veri Bilimi ve Analitiği Bölümü  
ETSTUR  
İstanbul, Türkiye  
sedat.kestepe@etstur.com

Olca Taner Yıldız  
Bilgisayar Mühendisliği Bölümü  
Işık Üniversitesi  
İstanbul, Türkiye  
olcay.yildiz@isikun.edu.tr

**Öz** —Otel sayısının her geçen gün arttığı turizm sektöründe, aracı firmaların tüm oteller ile ayrı ayrı çalışma imkanı bulunmadığından, firmalar dünya üzerinde bir çok otelle anlaşması bulunan servis sağlayıcılarıyla beraber çalışmaktadır. Farklı servis sağlayıcılarından alınan otel kayıtlarında tekrarlayan otel verileri olabilmektedir. Tekrarlayan bu kayıtlar aynı bilgilere sahip olabileceği gibi, farklı bilgilere sahip olmasına rağmen aynı oteli temsil edebilmektedir. Otel verilerini tutarlı hale getirmek için aynı oteli temsil eden kayıtlar eşleştirilmelidir. Bu amaçla, otel kayıtları üzerinde çalışarak, adres zenginleştirilmesi ve ön işleme yapılan aday kayıtlar için kategorik ve görsel verilerin benzerliklerinin kullanıldığı makine öğrenmesi algoritmaları uygulanmıştır. Yapılan işlem sonucunda, 132.287 satırlık otel verisinde 14.985 adet otel %99,12 doğruluk oranı ile eşleştirilmiştir.

**Anahtar Sözcükler**—Otel Eşleştirme, Makine Öğrenmesi, Tekrarlayan Kayıtların Tespiti, Metin Benzerliği, Görsel Benzerliği

**Abstract**—Having the day by day increasing number of hotel entities, travel agencies work with online hotel providers which have deals with lots of hotels around the world since dealing with the whole set of hotels individually is almost impossible. Whereas, working with online providers saves agencies from a big challenge, it degrades the problem of agency to another one: duplicate hotel records from different sources. The repeating records might either have all same set of identical features or features with different values that represent the same hotel. Matching and merging such records need to be applied for a consistent database. In this study, we propose a set of methods which aims solving the pointed problem. We work on hotel records, applied machine learning algorithms using string and image similarity on records for which address enrichment and pre-processing applied, selecting prior methods as baseline. Proposed method achieved 99.12% accuracy, matching 14.985 hotels on a 132.287 rows of data.

**Keywords**—Hotel Mapping, Machine Learning, Near Duplicate Detection, String Similarity, Image Similarity

### I. GİRİŞ

Dünyadaki otel sayısının milyonlarla ifade edildiği turizm sektöründe, otel sayısının yüksekliği aracı firmaların tüm oteller ile anlaşıp, müşterilerine sunmasını imkânsız kılmaktadır. Dolayısıyla, sektördeki firmalar veri havuzlarında birçok otelin bilgisini içeren tedarikçilerle anlaşarak, bu havuzlardaki otelleri pazarlamaya çalışmaktadır. Fakat, aynı otel farklı tedarikçilerin veri havuzunda farklı bilgilerle yer alabilmektedir. Bu durum, farklı tedarikçilerle çalışan firmaların veri tabanlarında aynı otelin birden fazla kez yer alması gibi bir soruna sebep olmaktadır. Bunun sonucunda, operasyonel ve sistemsel olarak düzeltilmesi zor birçok problem ortaya çıkmaktadır.

Bu çalışmada, üç farklı kaynaktan beslenen 132.287 otel kaydı içeren veri havuzu kullanılmıştır. Veride özellikleri aynı olan mükerrer kayıtlar olduğu gibi, aynı oteli temsil etmesine rağmen bazı özellikleri belli ölçülerde farklılık gösteren kayıtlar da bulunabilmektedir. Bu problem, mevcut durumda kural tabanlı bir yöntem kullanılarak tespit edilmeye çalışılmaktadır. Kural tabanlı eşleştirmeye alternatif olarak geliştirilen bu çalışmada belirlenen kurallara uymayan, fakat aynı oteli temsil ettiği için eşleşmesi gereken kayıtların da tespit edilmesi amaçlanmıştır. Kurulan sistemin sonucu olarak yüksek olasılıkla aynı otel olduğuna karar verilen kayıtlar otomatik olarak birleştirilmekte, orta ve düşük ihtimalle aynı otel olduğuna karar verilen oteller operasyonel ekiplerin incelemesi için onaylarına düşürülmektedir. Operasyonel ekiplerin manuel yaptığı işlemler modelin iyileştirilmesi için kullanılmaktadır.

Veri özniteliklerinin nasıl seçildiği, öznitelik ağırlıklarının nasıl belirlendiği, kullanılan algoritmalar ve eğitilen modeller bu bildirinin konusunu oluşturmaktadır. Çalışmamızda uygulanan geliştirme modelinin genel akış diyagramı Şekil 1'de görülmektedir.

Makalenin II. bölümünde bu bildiride temel alınan geçmiş çalışmalara, III. bölümde kullanılan verinin özelliklerine özneliklerin ve ağırlıklarının nasıl belirlendiğine, IV. bölümünde problemin çözümü için kullanılan yöntemlere, V. bölümde uygulamanın başarısına ve gerçek hayatta alınan sonuçlara yer verilmiştir.

## II. LİTERATÜR ÖZETİ

Tekrarlayan kayıtların tespiti konusunda temel çalışmalar ve tekrarlayan otel kayıtlarının tespiti için geliştirilen yöntemler bu çalışmaya temel oluşturmaktadır. Kozhevnikov ve Gorovoy [1], makalelerinde Rusya pazarı için çalışmış ve 2,8 milyondan fazla oteli kapsayan bir çalışma yapmışlardır. Otelleri önce gruplara ayırıp daha sonra benzer kayıtları bulmak için otelin temel özellikleriyle birlikte görsellerini de kullanmışlardır. Otelleri sınıflandırırken en iyi sonuç 30 ağaçlık bir rassal ormanlar sınıflandırıcısı ile elde edilmiştir. Benzer kayıtları tespit ederken makine öğrenmesi kısmında otel görselleri kullanıldığında, kullanılmadığı duruma göre daha yüksek başarı elde edilmiştir. Perez [2], otel kayıtları üzerinde yaptığı çalışmada aynı oteli temsil eden farklı kayıtları makine öğrenmesi yöntemiyle tespit etmeye çalışmıştır. AdaBoost ve XGboost algoritmalarıyla daha iyi sonuçlar elde etmiştir. Koumarelas ve diğerleri [3], Amerika Birleşik Devletleri'ndeki adres ve konum bilgilerinin mevcut olduğu oteller arasında, tekrarlayan kayıtları belirledikleri çalışmalarında karakter tabanlı ve vektör tabanlı benzerlik yöntemlerini birlikte kullanmışlardır. Adres bilgilerinin zenginleştirilmesi için OpenStreetMap gibi açık kaynaklı servislerle coğrafi kodlama ve ters-coğrafi kodlama yöntemlerinin yanı sıra, koşullu işlevsel bağımlılıkları kullanılarak zenginleştirme işleminde hata oranını azaltmışlardır. Turizm sektöründe bir firmanın verisini kullanan Bayrak ve diğerleri [4], mükerrer müşteri kayıtlarını benzerlik algoritmaları ve makine öğrenmesi yöntemleri kullanarak tekilleştirmeye çalışmışlardır. Destekçi vektör makinesi algoritmasını kullandıkları sınıflandırma modelinde daha başarılı sonuçlar elde etmişlerdir. Zheng ve diğerleri [5] coğrafi konumlar içeren ve farklı kaynaklardan beslenen bir veri kümesi üzerinde, aynı kaydı temsil eden benzer kayıtları bulmak için sınıflandırma algoritmaları kullanarak bir çalışma yapmışlardır. Birebir eşleştirme ve kural bazlı yaklaşıma göre çok daha başarılı sonuçlar elde etmişlerdir.


## III. VERİ

### A. Veri Ön İşleme

Çalışmamızda kullanılan otel verileri üç farklı kaynaktan alınmıştır. Farklı kaynaklardan bir araya getirilen veri, analiz sonucunun daha tutarlı olabilmesi için ön işlemeden geçirilmiştir. Bununla beraber, verilerde hatalar da mevcut olabileceğinden, hatalı olan veriler düzeltilip standart hale getirilmiştir.

Çalışmamızda kullanılan adres, şehir, ülke ve koordinat bilgileri üzerinde ön işleme uygulanmıştır. Adres bilgisi farklı kaynaklardan farklı formatlarda veya yazım yanlışlarıyla gelebilmektedir. Bunları standart hale getirmek amacıyla adres bilgisi olan oteller için bu bilgi ile Google Haritalar uygulama

programlama arabirimine sorgu yapılmıştır. Yapılan çağrı parametresi, adres bilgisinde eksiklik olacağı ihtimaline karşın otel ismi ve otel adresi parametre olacak şekilde beraber kullanılmıştır. Çağrı sonucunda dönen; koordinat, şehir ve ülke bilgileriyle eksik olan veriler doldurulmuştur. Adresin ayrıntılı girilmediği ve bunun sonucunda Google Haritalar uygulama programlama arabiriminden birden fazla adres döndüğü durumlarda; şehir ve ülke bilgisi, sadece dönen tüm yanıtlarda aynı olması durumunda kullanılmıştır.



Şekil 1: Akış Diyagramı

Bununla beraber, adresi olmayan ya da eksik olan, bu yüzden adresten şehir ve ülke bilgisinin çıkarılamayacağı kayıtlardaki hatalı adres bilgisi atılmış, şehir ve ülke bilgisi için düzenleme yapılmıştır. Bu işlemden, ülke ve şehir isimleri, doğru yazılışlarının olduğu küme ile karşılaştırılarak alt sınırı en az %80 olmak üzere en çok benzedikleri bilgilerle değiştirilmiştir (Tablo I). Bu oranın altında olan, kümedeki hiçbir değere yeteri kadar benzemeyen şehir ve ülke bilgileri atılmıştır. Benzerlik ölçümünde Levenshtein, cosine ve Jaro-Winkler benzerlik algoritmaları kullanılmıştır. Farklı benzerlik algoritmaları kullanılarak sonuç daha tutarlı hale getirilmiştir.

Eksik olan koordinat bilgisi, adres verisi ile Google Haritalar uygulama programlama arabirimine yapılan çağrı sonucu doldurulmuştur. Adres bilgisinin eksik olması sebebiyle koordinat bilgisinin Google Haritalar uygulama programlama arabiriminden alınamadığı durumlarda, koordinat yapısına uymayan veriler elenmiştir (Tablo I).

### B. Verinin Hazırlanması

Çalışmada 132.287 adet, elliden fazla ülkeden gelen otel verileri kullanılmıştır. Kullanılan otel verisi ilişkisel veri tabanında tablo yapısında tutulmaktadır. Her satırdaki otel verisinin

Tablo I: VERİ ÖN İŞLEME

| Öznitelik | Orijinal Veri       | Ön İşlemeden Geçirilmiş Veri                                                      |
|-----------|---------------------|-----------------------------------------------------------------------------------|
| ADRES     | blg 42391, center   |                                                                                   |
| ADRES     | Kadıköy 31, 34710   | CAFERAGA MAHALLESİ, ALBAY FAİK SOZDENER CD. NO:31, 34710 KADIKOY/ISTANBUL, TURKEY |
| ŞEHİR     | Taksim              | ISTANBUL                                                                          |
| ŞEHİR     | İreland             |                                                                                   |
| ÜLKE      | TR                  | TURKEY                                                                            |
| ÜLKE      | Denmark             | DENMARK                                                                           |
| KOORDİNAT | -37.484965000000003 |                                                                                   |
| KOORDİNAT | 55.833133199999999  | 55.833133199999999                                                                |

bir diğeriyle aynı oteli temsil etme ihtimali vardır. Otellerin birbirlerine ne kadar benzediğinin anlaşılması için satırlardaki otel verileri birbirleriyle karşılaştırılmalıdır.

Her bir satırdaki otel verisinin tüm satırlardaki verilerle karşılaştırılması için Kartezyen çarpımı, verinin büyüklüğünden ve  $O(n)^2$  karmaşıklığından dolayı mümkün olmamaktadır [6]. Bunun yerine; tablodaki satırlar, iki kaydın aynı otel olduğunu belirtebilecek her bir kolon ile oluşturulmuş birleştirme anahtarları ile kolon bazında birleştirilmiştir. Bu sayede,  $132.287^2$  satır veri yerine  $3.127.391$  satır aday veri kümesi oluşturularak zaman ve performans tasarrufu sağlanmıştır. Daha sonra, birleştirme ile oluşturulan sonuçlar alt alta eklenmiştir. Satırlardaki veriler yan yana getirilirken içsel birleştirme işlemi yerine, içsel birleştirmenin özel bir durumu olan ve kayıtların kendileriyle eşleşmelerinin önüne geçen öz birleştirme işlemi kullanılarak,  $27.128.702$  satırlık veri miktarı düşürülerek  $3.127.391$  satırlık bir veri kümesi oluşturulmuştur [7]. Böylece satırların kendileriyle eşleşmeleri önlenerek sonradan elenecek gereksiz eşleşmelerin önüne geçilmiştir.

Birleştirme yapılacak otel ismi kolonundaki boşluklar atıldıktan sonra veriden; sadece sesli, sadece sessiz, birer harf atlayarak birleştirme anahtarı oluşturulmuştur. Bu sayede, yazım hatalarından dolayı eşleşmeyecek otel isimlerinin eşleşme ihtimali artırılmıştır.

İki kaydın yeteri kadar benzemesi durumunda, kayıtlar otel ismi özniteliklerinden eşleşmezse, koordinat ya da diğer öznitelikler üzerinden eşleşecektir. Birleştirme sonuçları alt alta eklendikten sonra, farklı birleştirme işlemlerinden aynı eşleşmelerin gelme ihtimali olduğundan aday ikili kümesindeki birebir aynı olan satırlar, sadece bir tane kalacak şekilde düzenlenmiştir.


#### IV. YÖNTEM

##### A. Verideki Benzerliğin Ölçülmesi

Yan yana getirilen ikili aday çiftler arasında benzerliğe bakılmıştır. Bunun için kategorik olan otel ismi, şehir, ülke ve adres verileri için metin benzerliği ölçümleme yöntemleri kullanılmıştır. Karakter tabanlı olan Levenshtein ve Jaro-Winkler benzerlikleri ve vektör tabanlı olan cosine benzerliği [8] kullanılarak oluşabilecek farklı durumları yakalamak için bu algoritmaların ürettiği benzerlik değerleri öznitelik olarak

alınmıştır. Koordinat verileri benzerliği ölçülürken enlem ve boylam verileri birbirlerinden çıkarılıp  $\{0, 1\}$  arasına normalize edilerek iki yeni öznitelik oluşturulmuştur.

Otel görsellerinin karşılaştırılmasında ölçek bağımsız öznitelik dönüşümü (SIFT) algoritması kullanılmıştır. Bu algoritmanın seçilmesinin sebebi, algoritmanın, dönme, ölçekleme, parlaklık değişikliği, kontrast ve imajda gürültü olması gibi durumlarda başarılı bir şekilde çalışmasıdır [9]. Bu algoritma sayesinde oteller, görsellerde farklı boyut, konum ve açılarda yer alsalar bile benzerliklerinin ölçülmesi sağlanmıştır. Şekil 2’de iki otel görselinin aynı olduğu tespit edilen noktaları görülmektedir. Otel görsellerinin birden fazla olduğu durumlarda, en yüksek benzerlik oranı ve ortalama benzerlik oranları öznitelik olarak eklenmiştir.



Şekil 2: SIFT İle Resim Eşleştirme

##### B. Eğitim Kümesinin Seçimi

Bilgileri yan yana getirilerek oluşturulan aday ikililer arasından makine öğrenmesi adımı için, aday ikililerin aynı oteli temsil etmesi durumunda 1, temsil etmemesi durumunda 0 değeri verilecek şekilde işaretleme yapılmıştır. Otellerin, formatlanmış adres ve isim bilgilerin ortalama %80 oranında benzeyen ve aynı zamanda aynı koordinat bilgilerine sahip olan kayıtlar 1 olarak işaretlenmiştir. Ayrıca, benzer otel ismi ve aynı koordinata sahip aday ikililer ile, benzer adres ve aynı koordinata sahip aday ikililer arasından kayıtlar iş birimi tarafından uzman bilgisiyle manuel olarak 1 ya da 0 olarak işaretlenmiştir. Geriye kalan kayıtlar arasından, normal dağılım ile rasgele seçilen kayıtlar 0 olarak işaretlenmiştir. Böylelikle, 234.961 adet kayıt 1 ve 247.184 adet kayıt 0 olacak şekilde bir eğitim kümesi hazırlanmıştır.

##### C. Makine Öğrenmesi İle Otellerin Eşleştirilmesi

Çalışmada, iş birimi tarafından uzman bilgisiyle yapılan işaretleme işlemi sonucunda ortaya çıkan eğitim kümesinin ve Tablo II’deki özniteliklerin kullanıldığı iki sınıflı bir model kullanılmıştır.

Aday ikililerin aynı oteli temsil edip etmeme durumuna göre sınıflandırılması için; rassal ormanlar, destekçi vektör makinası ve yapay sinir ağları algoritmaları kullanılmıştır. Sınıflandırma yapılmadan önce yüzde birlik dilime giren aykırı değerlerin olduğu satırlar çıkarılmış, geri kalan öznitelikler en küçük değer 0, en büyük değer 1 olacak şekilde ölçeklendirilmiştir.

Tablo II: ÖZNİTELİKLER

| Öznitelik                                      | Detay                                                                                                |
|------------------------------------------------|------------------------------------------------------------------------------------------------------|
| Otel Adı Levenshtein Benzerliği                | Otel adlarının arasındaki Levenshtein benzerliğinin $\{0, 1\}$ arasına normalize edildiği öznitelik  |
| Otel Adı cosine Benzerliği                     | Otel adlarının arasındaki cosine benzerliğinin $\{0, 1\}$ arasına normalize edildiği öznitelik       |
| Otel Adı Jaro-Winkler Benzerliği               | Otel adlarının arasındaki Jaro-Winkler benzerliğinin $\{0, 1\}$ arasına normalize edildiği öznitelik |
| Enlem Farkı                                    | İki aday otel arasındaki enlem değerlerinin farkı                                                    |
| Boylam Farkı                                   | İki aday otel arasındaki boylam değerlerinin farkı                                                   |
| Formatlanmış Adres Levenshtein Benzerliği      | Otel adresleri arasındaki Levenshtein benzerliğinin $\{0, 1\}$ arasına normalize edildiği öznitelik  |
| Formatlanmış Adres cosine Benzerliği           | Otel adresleri arasındaki cosine benzerliğinin $\{0, 1\}$ arasına normalize edildiği öznitelik       |
| Formatlanmış Adres Jaro-Winkler Benzerliği     | Otel adresleri arasındaki Jaro-Winkler benzerliğinin $\{0, 1\}$ arasına normalize edildiği öznitelik |
| Aynı Şehir                                     | İki otelin şehir bilgisi aynıysa 1, değilse 0 değeri alan öznitelik                                  |
| Aynı Ülke                                      | İki otelin ülke bilgisi aynıysa 1, değilse 0 değeri alan öznitelik                                   |
| Otel Görselleri Ortalama Benzerlik             | İki otelin farklı görsellerinin ortalama benzerlik oranı                                             |
| Otel Görselleri Arasındaki En Yüksek Benzerlik | İki otelin farklı görselleri arasında en yüksek benzerlik oranı                                      |

Tablo III'te görsel benzerlikleriyle ilgili öznitelikler olmadan, Tablo IV'te ise görsel benzerliklerinin de öznitelik olarak kullanılarak oluşturulan modellerin test sonuçları eğitim kümesinin beş katmanlı çapraz geçerlemesi ile elde edilmiş; doğruluk, kesinlik ve duyarlılık için ortalama başarı oranları verilmiştir. Algoritmalar için Python'ın scikit-learn kütüphanesi kullanılmıştır. Algoritmalarındaki parametrelerin optimizasyonu için parametreler belirli değer aralıklarında denenmiş, algoritmaların performansına bakılmıştır. Rassal ormanlar algoritması için ağaç sayısı belirlenirken  $[100, 600]$  aralığına bakılmış ve ağaç sayısı 300 olarak seçilmiştir. Destekçi vektör makinesi için C, gamma ve kernel parametreleri sırayla; 2154, 0.1 ve rbf olarak seçilmiştir. Yapay sinir ağlarında gizli katman sayısı 2 ile 10 değerleri arasında incelenmiş, katman sayısı için 4 seçilmiştir.

Tablo III: MODEL SONUÇLARI

| Algoritma                | Doğruluk(%) | Kesinlik(%) | Duyarlılık(%) |
|--------------------------|-------------|-------------|---------------|
| Rassal Ormanlar          | 98,11       | 97,46       | 97,33         |
| Destekçi Vektör Makinesi | 98,52       | 98,39       | 98,58         |
| Yapay Sinir Ağları       | 97,44       | 97,39       | 97,61         |

Tablo IV: İMAJ BENZERLİĞİNİN KULLANILDIĞI MODEL SONUÇLARI

| Algoritma                | Doğruluk(%) | Kesinlik(%) | Duyarlılık(%) |
|--------------------------|-------------|-------------|---------------|
| Rassal Ormanlar          | 98,49       | 98,82       | 97,78         |
| Destekçi Vektör Makinesi | 99,12       | 99,01       | 99,19         |
| Yapay Sinir Ağları       | 98,10       | 98,08       | 98,47         |

#### D. Makine Öğrenmesi ve Kural Tabanlı Yöntemin Karşılaştırılması

Bu makalede bahsi geçen çalışmadan önce otellerin eşleştirilmesi için kullanılan kural tabanlı yöntemde otellerin, isimleri ve koordinatları veya isimleri ve adreslerinin aynı olması durumunda eşleşeceği varsayılmıştır. Bu kurala göre farklı kaynaklardan gelen 132.287 adet otel verisinde 5.816 adet otel eşleşmesi bulunmuştur. Benzerlik ve makine öğrenmesi kullanılan yöntemle 14.985 adet eşleşme bulunduğu düşünüldüğünde yapılan çalışmanın önemi görülmektedir.

#### V. SONUÇ

Çalışmamızda, farklı kaynaklardan, farklı ülkelerdeki oteller için gelen, aynı standartta olmayan, eksik veri içeren ve farklı değerlere ya da özniteliklere sahip olmasına rağmen aynı oteli temsil eden otel kayıtları tekilleştirilmiştir. Bunun için ilk olarak, farklı kaynaklardan gelmiş veriler ön işlemeden geçirilerek eksik ya da yanlış kayıtlar düzeltilmiştir. Ayrıca, farklı olan veriler özniteliklerine göre standart hale getirilmiştir. Bununla beraber, adres bilgisi Google Haritalar uygulama programlama arabirimine parametre olarak verilerek dönen sonuç ile şehir, ülke ve koordinat bilgilerindeki eksiklik ve hatalar giderilerek veri daha tutarlı ve standart hale getirilmiştir.

Kayıtların aynı oteli temsil edip etmediğinin anlaşılması için, kayıtlar birbirleriyle karşılaştırılmıştır. Bu karşılaştırma zaman ve performans koşulları göz önüne alındığında Kartezyen çarpımı yerine, aynı oteli temsil etme ihtimali olan öznitelikler üzerinden öz birleştirme şeklinde yapılmıştır. Yan yana gelen aday ikililerin kategorik verilerinin benzerliği Levenshtein, cosine ve Jaro-Winkler algoritmaları ile ölçülerek yeni öznitelikler oluşturulmuştur. Otel imajları benzerliklerinin ölçümü için ölçek bağımsız öznitelik dönüşümü (SIFT) algoritması kullanılmıştır.

Tablo III'teki sonuçlardan da görüleceği üzere, kurulan modellerden destekçi vektör makinesi %98.52 oranında bir doğrulukla çalışarak aynı varlığı temsil eden farklı otel kayıtlarını eşleştirmiştir. Tablo IV'ten görüleceği üzere ölçek bağımsız öznitelik dönüşümü algoritmasıyla otel görsellerinde ölçülen benzerliğin öznitelik olarak kullanılması, sonuca olumlu yönde etki ederek model başarısını %99.12'ye çıkarmıştır.

Farklı kaynaklardan gelen 132.287 sayıda otel verisinde, kural tabanlı yöntem ile 5.816 sayıda otel eşleştirilirken, çalışmamız sonucunda 14.985 adet otel eşleşmesi gerçekleştirilmiştir.

#### KAYNAKLAR

- [1] I. Kozhevnikov and V. Gorovoy, "Comparison of different approaches for hotels deduplication," in *International Conference on Knowledge Engineering and the Semantic Web*. Springer, 2016, pp. 230–240.
- [2] F. D. Pérez Sena, "Accommodations deduplication," 2018.
- [3] I. Koumarelas, A. Kroschek, C. Mosley, and F. Naumann, "Experience: Enhancing address matching with geocoding and similarity measure selection," *Journal of Data and Information Quality (JDIQ)*, vol. 10, no. 2, p. 8, 2018.
- [4] A. T. Bayrak, A. İ. Yılmaz, K. B. Yılmaz, R. Düzağaç, and O. T. Yıldız, "Near duplicate detection in relational databases," in *2018 26th Signal Processing and Communications Applications Conference (SIU)*. IEEE, 2018, pp. 1–4.

- [5] Y. Zheng, X. Fen, X. Xie, S. Peng, and J. Fu, "Detecting nearly duplicated records in location datasets," in *Proceedings of the 18th SIGSPATIAL International Conference on Advances in Geographic Information Systems*. ACM, 2010, pp. 137–143.
- [6] S. Chatterji, S. Surya Kiran Evani, S. Ganguly, and M. Datt Yemmanuru, "On the complexity of approximate query optimization." 01 2002, pp. 282–292.
- [7] G. De Francisci Morales and A. Gionis, "Streaming similarity self-join," *Proceedings of the VLDB Endowment*, vol. 9, 01 2016.
- [8] W. Gomaa and A. Fahmy, "A survey of text similarity approaches," *international journal of Computer Applications*, vol. 68, 04 2013.
- [9] D. G. Lowe, "Distinctive image features from scale-invariant keypoints," *International journal of computer vision*, vol. 60, no. 2, pp. 91–110, 2004.