

CS549.TT Midterm #1

I. QUESTION (15 POINTS)

Construct trie data structure for the following 10 words: gidiyorum, gittim, giderken, git, gel, geldik, geldiydim, gitmişim, gelmiş, giderse.

II. QUESTION (20 POINTS)

Given the following sentences:

```
<s> ali topu at . </s>
<s> ali ayşeye çiçek al . </s>
<s> ali topu sev . </s>
<s> ayşe topu at . </s>
<s> ali ayşeye topu at . </s>
```

- Calculate the following unigram probabilities: $P(\text{ali})$, $P(< s >)$, $P(\text{ayşeye})$, $P(\text{at})$. Assume that no smoothing is applied (6 points).
- Calculate the following bigram probabilities: $P(\text{ali} | < s >)$, $P(\text{topu} | \text{ali})$, $P(< /s > | .)$, $P(\text{ayşeye} | \text{ali})$. Assume that no smoothing is applied (6 points).
- Calculate the following unigram probabilities: $P(\text{ali})$, $P(< s >)$, $P(\text{ayşeye})$, $P(\text{at})$. Assume Laplace smoothing is used (8 points).

III. QUESTION (12 POINTS)

Let us say we have 4 states:

S_1 : A, S_2 : C, S_3 : G, S_4 : T

with initial probabilities: $\Pi = [0.3, 0.4, 0.1, 0.2]$

and the transition matrix is:

$$\mathbf{A} = \begin{bmatrix} 0.2 & 0.2 & 0.3 & 0.3 \\ 0.1 & 0.3 & 0.2 & 0.4 \\ 0.4 & 0.4 & 0.1 & 0.1 \\ 0.1 & 0.1 & 0.1 & 0.7 \end{bmatrix}$$

- Calculate the probability of the sequence ACGT (6 points).
- Calculate the probability of the sequence CGTA (6 points).

IV. QUESTION (18 POINTS)

Let say we have the following sequence data.

ACGTACGT
AACCGGTT
CGTACGTA
GGCCAATT
TATAGCGC

- Calculate the initial probability vector (6 points).
- Calculate the transition probability matrix (12 points).

V. QUESTION (18 POINTS)

Write regular expressions for the following items:

- A student number starting with 2 or 3 digits, continuing with three English lowercase letters. 12abc, 134cda, ... (6 points)
- A file name consisting of a set of digits not starting with 0 and with extension train, dev or test. 123.train, 1345.test, 34.dev, ... (6 points)
- Zero or one digits, following zero or one English lowercase letters, following zero or one English letters. 1aA, a, 3, A, ... (6 points)

VI. QUESTION (17 POINTS)

- Take the derivative of the sigmoid function

$$F(x) = \frac{1}{1 + e^{-x}} \quad (1)$$

and prove that $F'(x) = F(x)(1 - F(x))$ (8 points)

- Take the derivative of the hyperbolic tangent function

$$G(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2)$$

and prove that $G'(x) = 1 - G(x)^2$ (9 points)