

CS449-CS549 Midterm #1

I. QUESTION (10 POINTS)

Construct trie data structure for the following 10 words: gidiyorum, gittim, giderken, git, gel, geldik, geldiydim, gitmişim, gelmiş, giderse.

II. QUESTION (15 POINTS)

Given the following sentences:

```
<s> ali topu at . </s>
<s> ali ayşeye çiçek al . </s>
<s> ali topu sev . </s>
<s> ayşe topu at . </s>
<s> ali ayşeye topu at . </s>
```

- Calculate the following unigram probabilities: $P(ali)$, $P(< s >)$, $P(ayşeye)$, $P(at)$. Assume that no smoothing is applied (5 points).
- Calculate the following bigram probabilities: $P(ali | < s >)$, $P(topu | ali)$, $P(< /s > | .)$, $P(ayşeye | ali)$. Assume that no smoothing is applied (5 points).
- Calculate the following unigram probabilities: $P(ali)$, $P(< s >)$, $P(ayşeye)$, $P(at)$. Assume Laplace smoothing is used (5 points).

III. QUESTION (16 POINTS)

Let us say we have an hidden Markov model with 2 states HOT and COLD; and three possible words in the output vocabulary 1, 2, 3.

with initial probabilities: $\Pi = [0.8, 0.2]$

the transition matrix:

$$A = \begin{bmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{bmatrix}$$

the emission probabilities:

$$B_{HOT} = \begin{bmatrix} 0.2 \\ 0.4 \\ 0.4 \end{bmatrix}$$

$$B_{COLD} = \begin{bmatrix} 0.5 \\ 0.4 \\ 0.1 \end{bmatrix}$$

- Draw the HMM. (2 points)
- Calculate the best hidden weather sequence for the observation sequence 1, 2, 3 using the Viterbi algorithm. (14 points)

IV. QUESTION (9 POINTS)

Let say we have the following sequence data.

```
ACGTACGT
AACCGGTT
CGTACGTA
GGCCAATT
TATAGCGC
```

- Estimate the initial probability vector (3 points).
- Estimate the transition probability matrix (6 points).

V. QUESTION (15 POINTS)

Given the following sentences, positive and negative categories; calculate the category for the given test sentences. Use Laplace smoothing to calculate probabilities.

Sentence	Category
hep tekrar hep tekrar	-
süper kötü bir film	-
çok iyi film	+
karakter gelişimi iyi	+
yazın en iyi film bu	+
çok süper film	?
iyi karakter çok kötü film	?

VI. QUESTION (15 POINTS)

In Turkish morphological disambiguation, there are two major problems. The first problem is the identify the correct root forms, and the second problem is to identify the correct morphemes. Assume that we are only interested in the first problem, and assume also that you have a morphologically disambiguated corpora. Propose a root form disambiguation algorithm to solve that problem. Use only algorithms until the end of the first midterm.

VII. QUESTION (10 POINTS)

Given two noun synsets S_1 and S_2 in the Turkish wordnet, propose an algorithm to find the shortest distance in the hypernym tree between S_1 and S_2 .

VIII. QUESTION (10 POINTS)

agree.01

Arg0: Agreeer

Arg1: Proposition

Arg2: Other entity agreeing

fall.01

Arg1: Logical subject, patient, thing falling

Arg2: Extent, amount fallen

Arg3: start point

Arg4: end point, end state of arg1

increase.01

Arg0: causer of increase

Arg1: thing increasing

Arg2: amount increased by, EXT, or MNR

Arg3: start point

Arg4: end point

Annotate the following sentences with the arguments above:

- The group agreed it wouldn't make an offer
- Sales fell to \$25 million from \$27 million
- John agrees with Mary on everything.
- The price of bananas was increased again by Big Fruit Co.
- The average junk bond fell by 4.2%